

Option B - Mission fictive - Analysez des images médicales avec des méthodes semi-supervisées



Comment allez-vous procéder ?

Cette mission suit un scénario de projet professionnel.
Vous pouvez suivre les étapes pour vous aider à réaliser vos livrables.

Avant de démarrer, nous vous conseillons de :

- lire toute la mission et ses documents liés ;
- prendre des notes sur ce que vous avez compris ;
- consulter les étapes pour vous guider ;
- préparer une liste de questions pour votre première session de mentorat.

Prêt à mener la mission ?

Vous êtes Data Scientist junior spécialisé en Computer Vision au sein de *CurelyticsIA*, une startup innovante dans le domaine de la e-santé. L'entreprise développe des solutions basées sur l'intelligence artificielle pour assister les professionnels de santé dans l'analyse d'images médicales, en particulier des IRM.

Dans le cadre d'un nouveau projet R&D, *CurelyticsIA* souhaite explorer la possibilité d'automatiser la détection de tumeurs du cerveau. Un ensemble conséquent de radios a été collecté : la majorité de ces images ne dispose d'aucun étiquetage, tandis qu'un sous-ensemble limité a été annoté par des radiologues experts.

Vous êtes chargé de concevoir une première exploration analytique du jeu de données. Plus précisément, votre mission est de :

- Explorer les images et extraire des caractéristiques visuelles via un modèle pré-entraîné ;
- Appliquer des méthodes de clustering pour identifier des structures ou regroupements dans les données ;
- Mettre en œuvre une méthode d'apprentissage semi-supervisé à partir des quelques étiquettes disponibles ;
- Synthétiser vos résultats, formuler des recommandations, et les présenter à votre équipe projet.

Vous recevez un mail de votre responsable Data Science, Clara Martin, qui vous partage les détails du projet :

De : Clara

À : Moi

Objet : Mission d'exploration et de modélisation - Données radios

Bonjour,

Comme discuté lors de notre dernière réunion, tu es assigné à la première phase du projet *BrainScanAI*. Tu trouveras en pièce jointe un **fichier zip** contenant :

- Le jeu de données de radiographies (en format PNG + métadonnées anonymisées),
 - Une documentation technique sur le format des images ;
 - Une liste restreinte de labels annotés par nos partenaires hospitaliers (normal/cancéreux).
- Pour info, notre budget actuel pour la labellisation par IA est de 300 euros pour ce dataset.

Tes objectifs :

1. Extraire des caractéristiques visuelles pertinentes à l'aide d'un modèle pré-entraîné (type ResNet ou équivalent).
2. Réaliser un clustering exploratoire pour identifier des regroupements naturels.
3. Mettre en œuvre une méthode semi-supervisée en exploitant les labels partiels pour prédire les étiquettes manquantes.
4. Proposer des livrables au format **Notebook** contenant :

- l'extraction des features
- le preprocessing adapté au(x) modèle(s) utilisés
- l'analyse non-supervisée (.ipynb)
- l'entraînement de modèles de clustering
- l'approche semi-supervisée (.ipynb)

Ces livrables doivent être accompagnés d'un **support de présentation** proposant des recommandations techniques pour un passage à l'échelle (budget de 5 000 euros pour 4 millions d'images à labelliser). Est-ce que ce passage te paraît faisable et si oui, sous quelles conditions ?

5. Rédiger une synthèse de ton approche et de tes résultats dans un support de présentation.

Les contraintes :

- Travailler en Python.
- Tester plusieurs algorithmes.
- Avoir des métriques pertinentes en fonction de l'erreur la plus importante (F1, Acc, Précision, ou autre ?).
- Clairement définir ce que tu considères comme un objectif atteint ("definition of done").

N'hésite pas à me faire un point d'étape avant la fin de semaine. Bon courage pour cette mission !

Clara

Responsable Data Science

Curelytics/IA

PJ : [fichier Zip](#)

Suivez les étapes ci-dessous.

Étapes

Commencez par charger le dataset fourni par Clara. Effectuez une exploration visuelle des images, vérifiez leur résolution, canal de couleur et structure de fichiers.

Prérequis

Avoir installé les bibliothèques nécessaires (Pillow, matplotlib, etc.)

Résultat attendu

Vue d'ensemble du jeu de données, images d'exemple affichées et observations notées.

Recommandations

- Travailler sur un échantillon réduit pour les premières étapes.
- Vérifier la qualité et la cohérence des données.

Outils :

PyTorch, torchvision, NumPy, pandas, matplotlib

Préparez les images (redimensionnement, normalisation) et utilisez un modèle pré-entraîné (ex : ResNet) pour extraire des embeddings visuels.

Prérequis

- Avoir nettoyé et formaté les données image.
- Avoir compris le fonctionnement des CNNs.

Résultat attendu

- Vecteurs de features pour chaque image, sauvegardés dans un tableau exploitable.

Recommandations

- Geler les couches convolutionnelles.
- Évaluer plusieurs couches d'extraction si besoin.

Outils

- Torchvision / TensorFlow / Transformers
- numpy,
- pandas,
- matplotlib,
- opencv-python

Réduisez la dimension des features (PCA, t-SNE) et appliquez un clustering (K-Means, DBSCAN) pour identifier des regroupements d'images similaires (avec le même nombre de groupes que votre dataset labellisé ici 2). Le but est de labelliser de façon non-supervisée les images pour lesquelles vous n'avez pas de label. On parle alors de labellisation "faible".

Attention ! Gardez bien ce jeu de données “faiblement” labellisé séparé du jeu de données “fortement” labellisé (pour lequel vous avez les labels de base). Il ne faut jamais les mélanger !

Prérequis

Avoir un tableau de features standardisé

Instructions

- Réduire la dimensionnalité avec PCA ou t-SNE pour visualisation
- Appliquer un clustering (ex : K-Means, DBSCAN) ;
- Visualiser les résultats et interpréter les regroupements.
- Déterminer via le score ARI (avec les données “fortement” labellisées) si vous êtes sur le bon chemin ou non.

Recommandations :

- Standardiser les features
- Tester plusieurs méthodes de clustering
- Ne pas s'attendre à un résultat parfait via le score ARI.

Outils

scikit-learn, seaborn, matplotlib, plotly

Résultat attendu

Des graphes 2D illustrant les clusters, accompagnés de commentaires.

Entraîner un modèle de type CNN sur votre jeu de données “faiblement” labellisé dans un premier temps puis et évaluer ses performances. Poursuivez ensuite l'entraînement de ce même modèle sur le jeu de données “fortement” labellisé. Comparer ensuite la différence de performance entre entraînement supervisé (modèle entraîné sur le jeu de données “fortement” labellisé uniquement) et semi-supervisé (entraîné sur les 2 jeux de données).

Prérequis

- Avoir préparé un ensemble labellisé et un ensemble non labellisé

Résultat attendu

- Modèle entraîné et validé avec les métriques choisies (accuracy, F1-score ou autre ?)

Recommandations

- Réaliser un split train/test équilibré
- Pour chaque évaluation des performances: attention à ce que le jeu de test soit bien des données jamais vues par le modèle évalué lors de son entraînement.
- Utiliser des visualisations bien lisibles pour analyser les performances.

Outils

- Torchvision / TensorFlow / Transformers
- numpy,
- pandas.

Complétez la [fiche d'autoévaluation](#).